

Ecole Supérieure de Technologie de Fès (ESTF)



DBT GL– Semestre 2 **Chapitre 4**

Prétraitement des Données
(Data Preprocessing)

HADIOUD Ferdaous

(ferdaous.hdioud@usmba.ac.ma)

Année Universitaire: 2025/2026

Les principales étapes du processus d'analyse de Données:

Rappels



Le Pipeline IA

Bases de données,

- Suppression des erreurs


- Gestion des valeurs manquantes

API, capteurs





- Enrichissement - Normalisation



- Agrégation



- Data Versionning



- Surveillance & maintenance

- Data drift
- Réentraînement

- Normalisation
- Standardisation



Objectifs du Chapitre

- Encodage.
- Features Selection

À la fin de ce chapitre, vous deviez être capables de: -

Features Engineering

✓ Comprendre l'importance du prétraitement des données dans l'analyse.

✓ Identifier et traiter les valeurs manquantes et aberrantes. ✓

Réduire la dimensionnalité et détecter les doublons. ✓ Appliquer des

techniques de transformation des données:

- ✓ Préparer un jeu de données propre et exploitable pour une analyse avancée.

I. Introduction

1. L'AD c'est quoi?

2. Pourquoi est elle importante?

2. Les Valeurs Manquantes

3. Les Valeurs Aberrantes

4. Les Doublons

III. La Transformation

1. Standardisation et Normalisation 2. Encodage

Plan du Chapitre

3. Features Selection



4. Réduction de dimensionnalités IV. Conclusion

- Le ~~preprocessing (prétraitement)~~ des données) est une étape essentielle ~~pour~~ garantir la qualité et la fiabilité de l'analyse.
- Il ~~consiste à nettoyer, transformer~~ et structurer les données pour ~~qu'elles soient exploitables.~~
- C'est une étape ~~essentielle qui consiste à préparer les données avant l'entraînement d'un~~ modèle d'apprentissage automatique ou l'analyse des données (~~la~~ modélisation).



I. Introduction

- Cette préparation des données passe par plusieurs ~~aspects, notamment :~~

Objectifs & Mesures

- 🌐 Nettoyer les **valeurs aberrantes**

🌐 Sélectionner les variables les plus pertinentes (~~features' Selection~~) 🌐 Combiner les variables ensemble pour en former de nouvelles (~~features~~) 🌐 Sélectionner certains groupes de valeurs

🌐 Effectuer des transformations logarithmes, exponentielles, etc. (~~Engineering~~)

🌐 ...

- Elle correspond l'ordre dans lequel effectuer les opérations de preprocessing avant de passer à la modélisation
- ~~Il existe plusieurs façons de faire qui dépendent du projet sur lequel on~~
- ~~Durant ce cours, on verra un certain nombre de ces recettes qui fonctionnent très bien.~~
- Pour commencer, la recette suivante est celle qui est la plus populaire et qui

donnera presque toujours de bons résultats.

I. Introduction

Séquence de prétraitement travaille.



Objectifs et Mesures

Concept ~~Type~~ ~~Signification~~ ~~Exemple~~ ~~NA~~ ~~Valeur spéciale~~ ~~Donnée manquante~~ ~~observation~~

absenteNaN Valeur numérique spéciale Résultat math

II. Nettoyage

1. Généralités

tout vecteur vide

Son objectif est de Supprimer les erreurs et incohérences.

✓ Gérer les valeurs manquantes

- Suppression des lignes/colonnes avec trop de valeurs manquantes: NA (Not Available), NULL, NaN (Not A Number).
- Imputation (remplacement) par la moyenne, médiane ou valeur par défaut.

invalide 0/0

NULL Objet vide Pas de donnée du

Objectifs et Mesures

II. Nettoyage

1. Généralités

Son objectif est de Supprimer les erreurs et incohérences.

✓ Gérer les valeurs manquantes

- Suppression des lignes/colonnes avec trop de **valeurs manquantes**: NA (Not Available), NULL, NaN (Not A Number).
- Imputation (remplacement) par la **moyenne**, **médiane** ou **valeur par défaut**.

✓ Identifier et traiter les valeurs aberrantes

- Détection via des graphiques (boxplot, histogramme).
- Remplacement ou suppression selon l'analyse métier.



✓ Supprimer les doublons

- Vérification et suppression des entrées répétées.

✓ Corriger les erreurs de saisie

- Standardisation des noms, uniformisation des formats (dates, majuscules / minuscules).

Détection & Traitement

~~Pourquoi ces valeurs sont-elles un problème ?~~

- ~~• Peuvent biaiser les analyses et fausser les conclusions.~~
- ~~• Certains modèles ne supportent pas les valeurs manquantes (e.g. régressions, réseaux de neurones).~~

~~Identifier les valeurs manquantes~~

- ~~• Vérification de la présence de valeurs manquantes avec:~~

~~- Python (`df.isnull().sum()`)~~

- R (`colSums(is.na(df))`).
- Visualisation avec `missingno` (Python) et

II. Nettoyage

2. Les Valeurs Manquantes

Stratégies de traitement

- Suppression des observations/colonnes incomplètes (avec trop de valeurs•

Imputation statistique (moyenne, médiane, mode)

- Imputation avancée (régression, k-NN, interpolation)
 - Utilisation de modèles prédictifs pour estimer les valeurs manquantes.
- `ggplot` (R).

manquantes)

☾ Comprendre combien il y a de valeurs ainsi
~~que comprendre comment elles sont distribuées.~~

🌐 Scénario 1: Une distribution aléatoire des valeurs manquantes • Dans cette
situation, ~~le mieux est~~

d'éliminer dans ~~un premier temps les~~
~~différentes lignes contenant ces valeurs.~~

• On verra dans un second temps pourquoi

II. Nettoyage


~~on pourrait~~ aussi remplacer les NaNs, si

2. Les Valeurs Manquantes

~~cela revient~~ à éliminez trop de lignes

Diagnostic

• Pour savoir quelle option choisir, il faut commencer par diagnostiquer le dataset.



☾ Comprendre combien il y a de valeurs ainsi
~~que comprendre comment elles sont distribuées.~~

🌐 ~~Scénario 2:~~ les valeurs manquantes sont distribués en ligne.

- ~~Dans ce cas là, on va éliminer toute les lignes avec les valeurs manquantes.~~

II. Nettoyage

2. Les Valeurs Manquantes

Diagnostic

- Pour savoir quelle option choisir, il faut commencer par **diagnostiquer** le dataset. **N.B.**

Ici on voit un NaN tout seul sur une ligne, on va voir après comment le gérer, cela sera un peu différent

☾ Comprendre combien il y a de valeurs ainsi
~~que comprendre comment elles sont distribuées.~~

🌐 ~~Scénario 3:~~ les valeurs manquantes sont en colonne • Ici ~~on a une colonne majoritairement remplie de valeur nulle ou de champ nul.~~

- Dans cette situation on va **éliminer les colonnes** avec beaucoup de valeurs en

distribués



II. Nettoyage

2. Les Valeurs Manquantes

Diagnostic

- Pour savoir quelle option choisir, il faut commencer par diagnostiquer le dataset. N.B.

si on élimine les lignes, il ne restera plus beaucoup de données à utiliser.

question.

€ Comprendre combien il y a de valeurs ainsi
~~que comprendre comment elles sont distribuées.~~

🌐 Scénario 4: la distribution **en paquet**, par exemple on voit ici un grand paquet de •

Dans ~~ce cas~~, avant de prendre une

décision, ~~il faut analyser la situation. Il~~

~~faut se demander pourquoi les valeurs~~

~~manquantes~~ forment un grand paquet

alors ~~que~~ celles-ci sont censées être

II. Nettoyage

2. Les Valeurs Manquantes

distribuées aléatoirement. À moins

~~d'avoir~~ affaire à une série temporelle,

Diagnostic

- ~~il n'y a~~ aucune raison spéciale pour avoir

- Pour savoir quelle option choisir, il faut commencer par **diagnostiquer** le dataset. ~~ici un~~

~~regroupement~~ de NaNs

valeurs manquantes

◆◆ Question aux étudiants: Dans quel cas serait-il préférable de supprimer plutôt que d'imputer les valeurs manquantes?

~~D'une manière générale, voilà la philosophie conseillée:~~

☾ ~~Il faut toujours commencer par éliminer AVANT de remplacer. C'est la première. La raison est tout simplement que remplacer une valeur, veut dire l'inventer.~~

II. Nettoyage

- Or, on ne construit pas un modèle de ML sur des données approximatives.

2. Les Valeurs Manquantes

- Conservez uniquement ce que vous connaissez et ce que vous maîtrisez.

Diagnostic

règle.

Suppression des données

Si une colonne est peu corrélée à la target et contient

Si une maison dont ces informations, sont

II. Nettoyage

2. Les Valeurs Manquantes beaucoup de valeurs manquantes, alors

qu'elle est

manquantes, alors cette ligne est inexploitable

Il faut trouver le bon compromis entre

conserver des lignes et des colonnes, ce qui dépend du projet!

Pour ~~supprimer les données d'un dataset on va utiliser la méthode~~ `dropna()` de

`pandas` La variable Cible insignifiante!

⌚ pourquoi conserver cette ligne ? (Target)

⌚ pourquoi la garder ?

Suppression des données

Pour conclure...

II. Nettoyage 2. Les Valeurs Manquantes

Une colonne avec bcp

de valeurs manquantes

Indispensable Inutile

Supprimer les lignes
Éliminer la colonne

et garder la colonne
directement

Suppression des données

~~Si on constate que le modèle pourrait bénéficier de plus de données, après en~~
avoir

éliminé ☹ ~~Reprise des lignes et/ou colonnes mises de côté, puis tenter de les exploiter~~
~~avec la méthode de~~ remplacement.

II. Nettoyage

2. Les Valeurs Manquantes • Là-dessus, il est

IMPOSSIBLE de développer de modèle.

- Au lieu d'éliminer les lignes, il faut les remplacer ou en tout cas d'en remplacer _{une}

partie dans laquelle on a confiance au remplacement. **N.B. Il faut cependant garder à**
l'esprit que cela introduit un biais dans les données.

Remplacement des valeurs manquantes

- Lors du



~~remplacement des valeurs manquantes, on va introduire un biais et le but~~
est de le

minimiser • ~~La bonne démarche est d'effectuer une analyse fondamentale pour~~
~~remplacer manuellement ou bien avec un script, les différentes valeurs NaNs que les~~
~~données~~ • ~~Si cela n'est pas possible, alors~~ l'imputation ~~est le dernier recours~~ Exemple:
~~avec le dataset MPG, avec des informations manquantes sur Horse power :~~

II. Nettoyage

2. Les Valeurs Manquantes

🌐 Première démarche:

- Supprimer la colonne Horse Power est une erreur à ne pas commettre. - En effet, on peut très bien



chercher à la main ou créer un script, qui va chercher sur internet
contiennent.

la vraie valeur pour cette variable, en fonction du nom du modèle et de son année. 🌐 datasetde
qualité

Remplacement des valeurs manquantes

🌐 Remplacement par Statistiques:

- Consiste tout simplement à remplacer les valeurs manquantes par des statistiques.

~~par exemple avec la colonne Horse Power, ce qu'on va faire c'est calculer la~~

~~valeur moyenne de cette colonne (les valeurs existantes) et on va remplacer les NaNs~~

par
~~cette valeur moyenne~~

II. Nettoyage

2. Les Valeurs Manquantes



Le gros inconvénient de tout ça, c'est que l'on va maximiser les risques de **biais** et **d'erreurs** dans le dataset.

Remplacement des valeurs manquantes 🌐 Remplacement par

Similarités:

- ~~Pour éviter d'avoir une approche aussi naïve que celle des statistiques, on~~
~~pourra utiliser d'autres outils comme le KNN Imputer, qui consiste à trouver les~~
~~données les plus semblables et de les utiliser pour remplacer les NaNs~~ Pour remplacer
les
manquantes d'un
dataset on utilise
les méthodes:

II. Nettoyage

2. Les Valeurs Manquantes



valeurs


SimpleImputer et
KNNImputer de
scikit-learn.

II. Nettoyage

2. Les Valeurs Manquantes

Exemples:

🌐 En Python :



🌐 En R :





~~Exercice Applicatif: Tester différentes méthodes d'imputation sur le dataset titanic et~~

~~comparer les résultats.~~

II. Nettoyage

2. Les Valeurs Manquantes



Détection & Traitement

~~Exemple: si le but est de prédire le prix d'une maison en fonction de sa~~

surface habitable et que nous avons les données suivantes:


II. Nettoyage

3. Les Valeurs Aberrantes

La présence de ces valeurs va influencer le modèle
mieux possible dans le nuage de points
(s'approcher de ce point-là en vue de minimiser l'ensemble des distances).

Pourquoi ces valeurs posent-elles un problème ? Le modèle va tenter de rentrer du

- Peuvent fausser les statistiques descriptives et biaiser les modèles.
- Peuvent être dues à des erreurs de saisie, des capteurs défectueux, etc.



que les échantillons qui sont représentatifs du phénomène que l'on cherche à **Mais...** modéliser.

Détection & Traitement

~~🌐 IQR (InterQuartile Range) : valeurs en dehors de $[Q1 - 1.5IQR, Q3 + 1.5IQR]$. 🌐~~

~~Boxplots et scatter plots (Python: `seaborn.boxplot`, R: `ggplot`).~~

II. Nettoyage

3. Les Valeurs Aberrantes

Identifier les valeurs aberrantes

- Méthodes statistiques:

- 🌐 Z-score (écart à la moyenne en nombre d'écarts-types).

- Méthodes graphiques:



Il existe plusieurs méthodes de nettoyage des valeurs aberrantes : • Le nettoyage uni-varié, qui consiste à analyser **chaque variable** indépendamment les unes des autres afin de détecter les valeurs aberrantes qui peuvent s'y trouver. (IQR, Z-score, etc...)

- Le nettoyage multi-varié, par exemple avec isolation Forest ou bien l'algorithme LOF que nous verrons plus tard



Détection & Traitement

🌐 La méthode IQR (Inter Quartile Range)- Diagnostique Comment les différentes valeurs sont calculées?

- ~~Sur la boîte à moustaches sont schématisés :~~
 - ~~le 1^{er} quartile Q1 (partie inférieure de la boîte) qui représente 25% de la~~
 - le 2^{ème} quartile de Q1 à Q2, ou médiane

II. Nettoyage

représente les 25% suivantes

3. Les Valeurs Aberrantes

- le 3^{ème} quartile Q3, partie supérieure de la boîte
- les valeurs adjacentes « 2 moustaches » représentées par des rectangles verticaux de part et d'autre de la boîte. Ces valeurs sont situées à une distance maximum.

- Les boîtes à moustache sont utilisées pour les **variables continues** fonction de l'écart inter-quartile (Q3-Q1).
- boxplot(x) trace la boîte à moustaches



de la variable x représentant schématiquement $h: (Q3-Q1)$ correspond à la hauteur de la
sa distribution.

population

boîte.

Détection & Traitement

 La méthode IQR (Inter-Quartile Range)- Diagnostique

II. Nettoyage

3. Les Valeurs Aberrantes

📖 Q1; représente les premiers 25% de maisons, celles qui sont les plus petites

de superficie moins de 75m². 📖 Entre Q1 à Q2 représente les 25% de maisons

suivantes (50%du dataset) 📖 Le troisième quartile, qui représente les 25% suivants, (c-à-d 75%des maisons du

Exemple:

📖 Le quatrième quartile, qui correspond au reste des maisons de Q3 jusqu'au dataset)

maximum

Détection & Traitement

🌐 La méthode IQR (Inter-Quartile Range)- Diagnostique

II. Nettoyage

3. Les Valeurs Aberrantes

📖 À partir de ces quartiles, on peut déterminer où se situent des valeurs aberrantes, c'est-à-dire des valeurs qui s'écartent beaucoup trop de la masse centrale. 📖 La méthode consiste à commencer par calculer le 'range' entre nos différents quartiles, en utilisant la

formule suivante:

Exemple:

$$\text{IQR} = Q3 - Q1 = 300 - 75 = 225$$

Détection & Traitement

 La méthode IQR (Inter-Quartile Range)- Diagnostique  ~~Une fois le IQR est défini,~~

~~on va s'en servir pour définir tout autour de notre boîte une zone de sécurité au delà de laquelle toute valeur sera considérée comme une valeur aberrante. Ainsi, une valeur sera considérée comme aberrante, si elle ne rentre pas dans l'intervalle suivant:~~  Ici, nous avons donc l'intervalle $[-262.5; 637.5]$. ~~Dès lors, on utilisera ces valeurs pour dire que tout ce qui se situe en dehors de cette zone sera considéré comme une valeur aberrante. Et c'est ça qui définit la zone de nos moustaches lorsqu'on crée~~ une boxplot

II. Nettoyage

3. Les Valeurs Aberrantes

Exemple:

$[Q1 - 1.5 \text{ IQR}; Q3 + 1.5 \text{ IQR}]$



Donc on pourra dire que tout ce qui se situe en dehors des moustaches (ici à gauche du minimum et à droite de 637.5) sera considéré comme un **outlier**.



Détection & Traitement

Ses utilisations:

 ~~Détection des valeurs aberrantes : On considère généralement qu'une valeur est aberrante si son Z-score est supérieur à 3 ou inférieur à -3 (ou 2,5 selon le contexte).~~ 

~~Normalisation des données : Permet de comparer des variables avec des échelles~~

~~différentes.~~  Statistiques inférentielles : Utile pour les tests d'hypothèses et la loi

II. Nettoyage

3. Les Valeurs Aberrantes

 Systèmes de recommandation et Machine Learning : Peut être utilisé dans la transformation des données avant l'entraînement des modèles.

 La méthode Z-score



normale.

Détection & Traitement

 La méthode Local Outlier Factor (LOF)

 ~~La méthode IQR ne permet que de traiter les anomalies sur un seul axe.~~ Cette méthode ne suffit pas à détecter toutes

II. Nettoyage

donc gravement nuire à la performance de nos

les valeurs aberrantes




peut

3. Les Valeurs Aberrantes

Afin d'éviter ce genre de problème on utilise des

modèles de détection d'anomalie qui permettent de

détecter les valeurs aberrantes en analysant



toutes



les variables à la fois.  Parmis

ces méthodes on trouve LOF

modèles

Détection & Traitement

 La méthode Local Outlier Factor (LOF)

II. Nettoyage

3. Les Valeurs Aberrantes

Principe du LOF

- L'idée c'est de comparer la **densité locale** d'un point à celle de ses voisins.
- Le principe est de calculer les distances entre nos points afin de tracer une sorte de rayon d'action autour de chaque point, ce qui nous permet donc de trouver quels sont les points qui sont très isolés du reste du groupe.
- Un point est considéré comme une anomalie locale s'il est significativement moins dense que ses voisins.



Détection & Traitement

La méthode Local Outlier Factor (LOF)

Étapes du calcul

1. Déterminer les k-voisins proches: Trouver les k points les plus proches d'un point donné (en utilisant des métriques comme la distance euclidienne).
2. Calculer la densité locale: (local-reachability density - LRD) de chaque point en fonction des distances de ses k-voisins. La densité locale de p est l'inverse de la moyenne des distances de portée entre p et ses k-voisins :

II. Nettoyage

3. Comparer avec les voisins: Le LOF d'un point est le ratio entre sa densité locale et la densité moyenne de ses voisins:

3. Les Valeurs Aberrantes

4. Interpréter le score LOF:



et



🌐 $LOF \approx 1$: Le point est normal (p est dans une région de densité homogène.) 🌐 $LOF > 1$: Le point est un potentiel outlier (plus il est grand, plus l'anomalie est forte.) 🌐 $LOF < 1$: Le point est dans une région plus dense que ses voisins (peu fréquent.) où $|N_k(p)|$ est le nombre de k-voisins de p.

Détection & Traitement

🌐 ~~La méthode Local Outlier Factor (LOF)~~

~~Exemple d'implémentation en R~~

~~La librairie DMwR ou dbscan permet d'appliquer LOF en R.~~

II. Nettoyage

3. Les Valeurs Aberrantes





Interprétation: Les points rouges ont un LOF élevé, donc ils sont considérés comme des anomalies.

Détection & Traitement

 La méthode Local Outlier Factor (LOF)

 Flexible : ~~Fonctionne sur des datasets multidimensionnels.~~

II. Nettoyage

⚠ Choix du paramètre k: Il peut influencer les résultats (un k trop petit

3. Les Valeurs Aberrantes

risque de ne pas capturer les vraies anomalies). ⚠ Complexité computationnelle: Plus coûteux en calcul que des méthodes plus simples comme le Z-score.

Avantages du LOF

✅ Détection locale : Contrairement aux méthodes globales (Z-score, DBSCAN), LOF fonctionne bien dans des zones de densité variable.

✅ Pas besoin de distribution normale : Contrairement au Z-score, il ne suppose pas que les données suivent une distribution gaussienne.

Inconvénients

Détection & Traitement

- ~~Une autre méthode très efficace consistant à créer des ensembles d'arbres~~

~~de décision, donc des forêts d'arbres qui découpent l'espace de façon orthogonale et~~ qui

~~arrêtent leur développement à chaque fois qu'ils ont isolé un point.~~ • Statistiquement,

~~les premiers points à être isolés sont donc les points qui sont~~ très loin du groupe.

II. Nettoyage

3. Les Valeurs Aberrantes

🌐 La méthode forêts d'isolation (Isolation Forest)



Détection & Traitement

🌐 IQR (Interquartile Range) : ~~valeurs en dehors de~~ $[Q1 - 1.5IQR, Q3 + 1.5IQR]$. 🌐

~~Boxplots et scatter plots (Python: seaborn.boxplot, R: ggplot).~~

II. Nettoyage

3. Les Valeurs Aberrantes

Identifier les valeurs aberrantes

- Méthodes statistiques:

🌐 Z-score (écart à la moyenne en nombre d'écarts-types).

❓❓ **Exercice pratique:** Identifier et corriger les valeurs aberrantes dans un jeu de données
réel.

- Méthodes graphiques:

Stratégies de traitement

- Suppression si très éloignées et peu nombreuses.
- Correction basée sur des règles métier.
- Transformation logarithmique ou normalisation si distribution asymétrique.

Détection & Suppression

II. Nettoyage

4. Les Doublons

Pourquoi?

- Évite les biais dus aux répétitions inutiles.

?? Exercice rapide :





Trouver et éliminer les doublons du dataset fourni.

- Améliore la qualité des analyses.

🌐 En Python :

🌐 En R :

Objectifs et Mesures

- ~~Les distances dans les algorithmes de classification et clustering doivent être~~ Son

objectif : ~~Rendre les données~~ comparables et adaptées aux modèles ✓ Mise à

~~l'échelle des variables~~

- ~~Normalisation (Min-Max Scaling) : Ramène les valeurs entre 0 et 1.~~ • Standardisation

(Z-score) : Centre les données autour de la moyenne ($\mu=0$, $\sigma=1$).

III. Transformation

✓ Encodage des variables catégorielles

- Conversion en variables numériques (One-Hot Encoding, Label

Pourquoi transformer les données ?

- Les modèles peuvent être sensibles aux échelles des variables.

✓ Création de nouvelles variables

homogènes.

- Extraction d'informations à partir de dates, segmentation en classes d'analyse.



Encoding).

1. Normalisation & Standardisation

- ~~Sont des techniques de transformation des données utilisées pour~~ ajuster l'échelle ~~des variables numériques.~~
- ~~Elles sont essentielles pour éviter que certaines caractéristiques ayant des valeurs extrêmes dominant les autres.~~

- ~~Consiste à mettre toutes les variables d'un dataset sur une même échelle, généralement en les ramenant à des valeurs comprises entre 0 et 1 ou en les centrant autour de zéro avec un écart type égal à un.~~ |||.

Transformation

1. Normalisation & Standardisation

- Il est crucial de normaliser les variables pour plusieurs raisons : 🌐 Impact sur les modèles: Les variables avec des valeurs numériques plus grandes peuvent dominer celles avec des valeurs plus petites, ce qui peut biaiser les résultats.
- 🌐 Convergence des algorithmes: Les algorithmes d'apprentissage, tels que la déscente de gradient, convergent plus rapidement lorsque les données sont

normalisées.

🌐 ~~Calculs de distance: Dans les méthodes basées sur la distance (comme les K-means ou KNN), les variables non normalisées peuvent fausser les calculs de distance.~~

III. Transformation

- Il n'est pas nécessaire de normaliser la variable cible (target) sauf : 🌐 Pour certains types de modèles (par exemple les réseaux de neurones)

Normalisation

cela peut parfois augmenter la vitesse d'apprentissage

🌐 Lorsque la target s'étend sur des valeurs très élevées (e.g. le prix d'une maison) cela peut faciliter l'apprentissage de certains modèles.

1. Normalisation & Standardisation

On ~~considère un dataset contenant~~ la taille (en mètres) et le poids (en kilogrammes) de

~~plusieurs individus :~~ • Taille: valeurs comprises entre 1 et 2 mètres.

• Poids: valeurs comprises entre 40 et 100 kilogrammes.

~~Si nous utilisons un modèle linéaire de la forme :~~

~~--x1 représente la taille.~~

~~--x2 représente le poids.~~

~~--w1 et w2 sont les poids associés.~~

III. Transformation

Normalisation

Exemple:

$$y = w_1x_1 + w_2x_2 \text{ où :}$$



Sans normalisation, le poids (x2) aura une influence beaucoup plus grande sur la sortie du modèle que la taille (x1) en raison de son échelle plus large.

Normalisation: Min-Max 1. Normalisation & Standardisation • La normalisation

Min-Max met les données à l'échelle pour que toutes les valeurs soient comprises entre 0 et 1.

- ~~La formule est:~~

III. Transformation



Par exemple, supposons que nous ayons les valeurs suivantes pour une variable x :



On calcule ainsi $x_{\min} = 155$ et $x_{\max} = 170$. Calculons la normalisation pour 160 :



1. Normalisation & Standardisation

Standardisation: Z-score

- ~~La standardisation transforme~~ les données pour qu'elles aient une moyenne

~~de 0 et un écart-type de 1. La formule est~~ $z = \frac{x - \mu}{\sigma}$ ~~μ est la moyenne de la variable.~~

~~σ est l'écart-type de la variable.~~

~~Par exemple, pour les mêmes valeurs de x, on calcule $\mu = 171.6$ et $\sigma = 12.3$. On~~ calcule

la standardisation pour 160 :

III. Transformation



où :




On fera de même pour les autres valeurs.

1. Normalisation & Standardisation

III. Transformation

Comparaison





Exemple pratique en Python 1. Normalisation & Standardisation
III. Transformation



Quelle technique choisir? 1. Normalisation & Standardisation € La

Normalisation

✓ Simple à mettre en œuvre

✓ Préserve les distances proportionnelles entre les valeurs, ce qui peut être
bénéfique pour certains algorithmes.

✗ Sensible aux valeurs aberrantes (outliers), qui peuvent fortement influencer
l'échelle des données si de telles valeurs extrêmes sont

III. Transformation

présentes.



Quelle technique choisir? 1. Normalisation & Standardisation La

Standardisation

- ✓ ~~Moins sensible aux valeurs aberrantes.~~
- ✓ ~~Avantageux pour les algorithmes qui supposent que les données sont centrées et normalisées.~~
- ✗ ~~Ne limite pas les valeurs dans un intervalle spécifique.~~


III. Transformation

Quelques cas d'utilisations

1. Normalisation & Standardisation

III. Transformation

Certains algorithmes sont plus sensibles aux différences d'échelle des données que d'autres.





C'est quoi? 2. Encoding • L'encodage est un processus de transformation des

variables catégoriques en données numériques exploitables par les algorithmes de

Machine Learning. • ~~La plupart des modèles ne peuvent pas traiter directement des~~

~~variables textuelles (ex : "Homme"/"Femme", "Rouge"/"Bleu"/"Vert"), d'où l'importance~~

~~de l'encodage.~~ • ~~Par exemple, des variables telles que~~ cut, color ou clarity

~~dans le dataset « Diamonds » sont souvent exprimées en texte (e.g., Ideal,~~

~~Premium, Good).~~ Il est donc ~~essentiel de convertir ces catégories en valeurs~~

~~numériques avant d'entraîner~~
~~nos modèles~~



III. Transformation



Pourquoi est-t-il important?

- Les algorithmes ne traitent que des valeurs numériques.
- Les catégories doivent être représentées de manière significative.

a- Encodage d'étiquettes (Label Encoding)

Principe: ~~Chaque catégorie est convertie en un nombre entier.~~

~~Exemple:~~

III. Transformation

2. Encoding

Quand l'utiliser ?

- Lorsque la variable a peu de catégories et qu'il n'y a pas de relation d'ordre
- Pour des algorithmes comme les arbres de décision, qui gèrent bien les variables catégoriques.

✓ **Avantages** : Simple et efficace.

✗ **Inconvénients** : Introduit une relation ordinale entre les catégories, ce qui peut être problématique.

problématique.

a- Encodage d'étiquettes (Label Encoding)

Exemple en Python:

III. Transformation

Exemple en R:

2. Encoding





b- Encodage ordinal (Ordinal Encoding)

☾ Utilisé pour les variables ordinales, càd les variables dont les catégories ont

une relation d'ordre ou d'hierarchie. Principe: ~~Associe un nombre entier aux~~

~~catégories tout en respectant un~~ ~~ordre logique.~~ Exemple:

III. Transformation

2. Encoding



Quand l'utiliser ?

Si la variable catégorique a un ordre naturel (ex : niveaux d'éducation, échelle de satisfaction).

b- Encodage ordinal (Ordinal Encoding)

Exemple 2:

~~la variable cut pour les diamants peut avoir les valeurs suivantes, classées~~

du
~~moins bon au meilleur~~ : 1. Fair

2. Good

3. Very Good

4. Premium

5. Ideal



- ☾ Dans ce cas, nous attribuons des valeurs numériques qui respectent cet

III. Transformation

ordre hiérarchique :
Fair → 0 Good → 1

2. Encoding

Very Good $\rightarrow$ 2

Premium $\rightarrow$ 3

Ideal $\rightarrow$ 4

Il est crucial de respecter cet ordre pour que le modèle comprenne correctement les relations entre les catégories.

b- Encodage ordinal (Ordinal Encoding)



~~Exemple en Python (Seikit-Learn):~~

Exemple en R:

2. Encoding

III. Transformation





c- Encodage binaire (One-Hot Encoding)

€ ~~Utilisé pour les~~ variables nominales, ~~où les catégories n'ont pas~~

d'ordre ~~intrinsèque, comme les couleurs (bleu, rouge, vert, orange).~~ Principe:

~~Crée une colonne binaire pour chaque catégorie (0 ou 1):~~

~~Exemple : On crée une nouvelle variable binaire pour chaque catégorie~~

III. Transformation

2. Encoding

Chaque observation aura



un 1 dans la

colonne correspondant à sa catégorie et 0 dans les autres

c- Encodage binaire (One-Hot Encoding) Quand l'utiliser ?

- ~~Lorsque la variable a plusieurs catégories distinctes.~~
- ~~Adapté aux algorithmes sensibles aux échelles, comme les réseaux de neurones et les régressions linéaires.~~

III. Transformation

2. Encoding

✓ **Avantages:** Pas de relation numérique entre les catégories. ✗

Inconvénients: Augmente le nombre de colonnes si beaucoup de catégories.

c- Encodage binaire (One-Hot Encoding)

III. Transformation

2. Encoding

Exemple en Python (pandas)



Exemple en R(avec dummyVars de caret)



d- Encodage basé la cible (Target Encoding) Principe: Remplace
chaque catégorie par la moyenne de la variable cibleExemple: une variable

~~"Ville" et une cible "Prix moyen"~~

III. Transformation

2. Encoding

associée.



Quand l'utiliser ?

- Dans des problèmes supervisés, notamment en régression.
- Utile quand une variable catégorique a beaucoup de valeurs uniques.

d- Encodage basé la cible (Target Encoding)

~~Exemple en Python (pandas):~~

~~Exemple en R:~~



III. Transformation

2. Encoding





Comparaison des différentes méthodes

III. Transformation

2. Encoding

- L'encodage des variables catégoriques est une étape essentielle du prétraitement des

données. • Le choix de la méthode dépend de:

- 🌐 Du nombre de catégories
- 🌐 Du modèle utilisé
- 🌐 De la relation entre les catégories et la cible



Réduction de nombre de variables explicatives (inputs): ~~Consiste à~~

~~réduire la dimension des~~ n ~~observations disponibles de~~ $m(x \in \mathbb{R}^m)$ ~~à~~ $k(x \in \mathbb{R}^k)$, ~~avec~~

~~en général~~ $k < m$. ~~Cela répondra à un ou plusieurs objectifs :~~ 1. ~~Réduire le volume~~

~~de données à traiter, tout en conservant au mieux l'information « utile ».~~ ☾ ~~Nécessité de~~

~~Définir ce qu'est « information utile »~~

~~pour définir un critère à optimiser.~~ 2. ~~Améliorer le~~

~~rapport signal / bruit en supprimant des variables non pertinentes,~~ ☾

~~Nécessité de Définir ce qu'est une variable non pertinente.~~ 3. Réduire la

complexité d'un modèle décisionnel afin d'améliorer sa capacité de



III. Transformation

3. Features Selection

4. Simplifier la mise en production et la maintenabilité de la solution. 5. Améliorer la « lisibilité » des données, en mettant en évidence des relations entre variables ou

groupes de variables ☺ visualisation utile.

6. Répondre à la « malédiction de la dimension » (curse of dimensionality). généralisation.

Approches de réduction de nombres de variables: - ~~Selon l'objectif,~~

~~les critères et méthodes réduction peuvent différer:~~ - ~~Les principales~~

~~approches sont:~~

1. ~~la réduction de dimension: la construction de nouvelles variables, en~~ nombre

~~plus réduit mais obtenues comme des~~ combinaisons (linéaires , ~~non linéaires~~)

~~de variables initiales. Elle permet une plus grande flexibilité que la sélection de variables, en revanche les nouvelles variables~~ sont rarement interprétables (chacune étant une combinaison de plusieurs ^{variables initiales}).

III. Transformation

3. Features Selection

2. La sélection de variables (feature selection) on entend la sélection d'un sous-ensemble de k variables parmi les m variables initiales. Les variables sélectionnées gardent ainsi leur signification initiale. En revanche, cette solution est potentiellement sous-optimale car c'est un cas particulier de

la construction de nouvelles variables.

C'est quoi? 3. Features Selection • ~~En data science, il est courant d'avoir dans~~

les datasets un très grand nombre ~~de variables (Features).~~ • ~~En général, plus~~

~~on a de variables, plus on a de problèmes dans le dataset.~~ • La sélection ~~de~~

~~variables (Feature Selection) consiste à choisir les~~ meilleures caractéristiques

~~d'un dataset tout en éliminant celles qui sont~~ redondantes, peu
informatives ou nuisibles ~~pour un modèle.~~



III. Transformation

Commencer par développer des modèles avec les quelques variables que l'on

comprend bien dans le dataset.

Pourquoi faire de la Feature Selection ?

✓ Améliorer les performances du modèle en réduisant la complexité ✓ Éviter l'over-fitting en supprimant les variables inutiles ✓ Accélérer l'entraînement en réduisant le nombre de variables ✓ Faciliter l'interprétation du modèle

Les approches de sélection 3. Features Selection Il existe trois grandes

catégories de méthodes de sélection de variables : 1. Filtrage (Filter Methods):

Sélectionne les variables indépendamment du modèle (~~Variance threshold~~,

~~Test de corrélation~~, ANOVA, ~~Chi²~~, ~~Information~~ 2. Enrobage (Wrapper Methods):

Sélectionne les variables en testant directement leur impact sur un

modèle (e.g. ~~Recursive Feature~~ Elimination (RFE),



Forward/Backward Selection)

III. Transformation

3. Intégrée Basé sur le modèle (Embedded Methods): Intègre la sélection dans le processus d'apprentissage (e.g. LASSO, Random Forest Feature Importance)Gain)

Les approches de sélection 3. Features Selection Il existe trois grandes

catégories de méthodes de sélection de variables : 1. Filtrage (Filter Methods):

la sélection est réalisée suivant des critères définis sans faire appel à

un modèle prédictif (ou décisionnel) ultérieur.

Des critères de sélection comme:



~~- la minimisation de la redondance entre variables d'entrée~~ ~~- la maximisation de~~
~~l'information mutuelle entre une variable d'entrée et la~~ ~~variable à prédire - une~~
combinaison entre ces deux critères.

III. Transformation

+ Coût modéré car la sélection est faite en amont de la construction des modèles, - Peu optimal
car ce modèle n'intervient pas dans le processus de sélection.

Les approches de sélection 3. Features Selection Il existe trois grandes

catégories de méthodes de sélection de variables : 2. ~~Enrobage (Wrapper~~

Methods):

~~la sélection est réalisée par une coopération directe avec le modèle~~

~~prédicatif qui emploie les variables sélectionnées.~~ --Le critère de sélection

~~typique est la maximisation des performances du~~ modèle prédictif

~~ultérieur sur un ensemble d'observations de validation.~~ --Le

~~modèle prédictif et la sélection du groupe de variables~~ sont « emballés »

ensemble, d'où le nom de cette approche.; le critère de sélection est la

réduction de l'erreur du modèle décisionnel ($\sum_n |y_i - \hat{y}_i|$).|||.



Transformation



Les approches de sélection 3. Features Selection Il ~~existe~~ trois grandes

catégories de méthodes de sélection de variables : 3. ~~Intégrée~~ Basé sur le

modèle (Embedded Methods): l'opération de sélection de variables est

intégrée à la méthode de construction de modèle prédictif. - la construction

d'arbres de décision.



~~- l'introduction d'une régularisation L1 dans la fonction de coût du~~
prédictif. modèle

III. Transformation

Exemples:



Sélection par filtrage: basé sur la variance (Variance Threshold) Objectif:

Éliminer les variables qui varient très peu et qui n'apportent pas d'information

utile. Méthode: Supprime les colonnes avec une variance inférieure

(pas d'information utile). à un seuil fixé. Exemple en Python :

III. Transformation

~~Exemple en R:~~

3. Features Selection





✓ Avantage : Rapide, adapté aux grandes bases de données.

✗ Inconvénient : Ne tient pas compte de la relation entre les variables et la cible.

Sélection par filtrage: basé sur la corrélation ~~Exemple en Python:~~

III. Transformation

Exemple en R:

3. Features Selection

Objectif : Supprimer les variables fortement corrélées entre elles pour éviter la redondance.

Si deux variables ont une corrélation > 0.8 ou < -0.8 , on en supprime une.





✓ Avantage : Simple à mettre en œuvre.

✗ Inconvénient : Ne tient pas compte de l'impact des variables sur la cible.

Sélection par filtrage: Tests statistiques (ANOVA, Chi², Mutual Information) Exemple en

Python:

III. Transformation

3. Features Selection

Objectif : Sélectionner les variables ayant une relation forte avec la variable cible.



✓ Avantage : Sélectionne les variables ayant un fort impact sur la cible ✗ Inconvénient : Ne prend pas en compte les interactions entre variables

Sélection d'enrobage: Recursive Feature Elimination (RFE) ~~Exemple en Python:~~

III. Transformation

Exemple en R:

3. Features Selection

Objectif : Supprimer les variables les moins importantes, une par une, jusqu'à atteindre un nombre optimal.





Inconvénient : Coût computationnel élevé. ☒ Avantage : Sélectionne les variables les plus importantes pour un modèle donné.

Sélection d'enrobage: Forward/Backward

🌐 Forward Selection : ~~Ajoute progressivement les variables qui améliorent le modèle.~~

🌐 Backward Elimination : ~~Supprime progressivement les variables ayant le~~

~~moins~~Exemple en Python:

III. Transformation

3. Features Selection



d'impact.



✓ **Avantage** : Très efficace pour identifier les variables clés.

✗ **Inconvénient** : Très lent pour les grands jeux de données.

Sélection basée sur modèles: Régression LASSO (L1 Regularization) Objectif :

~~Réduit les coefficients de certaines variables à zéro, les supprimant ainsi.~~ Exemple en

Python :



Exemple en R:

III. Transformation

3. Features Selection





✓ Avantage : Sélection automatique des variables

✗ Inconvénient : Ne fonctionne bien que si les variables sont bien normalisées.

Sélection basée sur modèles: Importance des variables avec Random Forest

Objectif : ~~Évaluer l'importance des variables en fonction de leur impact sur la~~

réduction
~~de l'erreur.~~

~~Exemple en Python:~~

Exemple en R:

III. Transformation

3. Features Selection





Inconvénient : Moins interprétable que

LASSO.

✓ Avantage : Fonctionne bien même sur des données non linéaires.

🌐 Enrobage → ~~Plus précis mais coûteux en calcul.~~

~~Comment choisir la bonne méthode~~

~~Le choix de la méthode dépend du contexte (nombre de variables, type de modèle, temps de calcul disponible).~~

III. Transformation

3. Features Selection

Dataset très large (beaucoup de

Conclusion

Optimisation fine d'un modèle Méthodes enrobées (RFE, Forward Selection)



Il existe plusieurs méthodes, chacune avec ses avantages :

Intégration automatique dans un modèle Méthodes basées sur le modèle (LASSO, Random

🌐 Filtrage → Rapide mais moins précis.

Besoin d'explicabilité Sélection manuelle ou importance des features

🌐 Basé sur le modèle → Automatique et efficace.

Méthodes de filtrage (corrélation, ANOVA)
variables)

Forest)

C'est quoi? 4. Features Engineering • ~~Méthode consistant à créer de nouvelles~~

variables à partir des données de départ afin ~~de faciliter l'apprentissage du modèle.~~

- ~~Par exemple, ci-dessous, nous avons deux classes de points (rouges/bleus):~~

III. Transformation

On ne peut pas séparer ces points
avec un simple modèle linéaire


(simple droite / en un plan) **Mais...** Les données sont devenue séparables avec un simple plan. 🌐 les

variables sont levées au carré (càd les données initiales sont centrées et élevées
toutes au


🌐 Après cette transformation les points qui sont relativement proches du centre

vont rester proches de zéro puisque zéro au carré nous donne toujours zéro. Mais les points en

bordure prendront de la hauteur sur l'axe $x_1^2 + x_2^2$ ☾



séparation le
avec un simple
plan (espace



tout

3D).

Explication:

carré).

Les principales opérations de feature engineering : 1. Création de nouvelles variables

🌐 ~~Exemple : à partir d'une date de naissance → créer une variable "âge"~~ 2.

~~Transformation des variables existantes~~

🌐 ~~Logarithme, racine carrée, binning (catégorisation de variables continues)~~ 3.

~~Encodage des variables catégorielles~~

III. Transformation 4. Features Engineering 4.

Normalisation/Standardisation

5. Sélection de features



🌐 Transformer un texte en nombre de mots, fréquence de mots, etc. 6. Combinaison ou interaction de variables

🌐 Extraction de composantes principales (réduction de dimension) 🌐 One-Hot, Label

Encoding, Target Encoding, etc.

🌐 Adapter l'échelle des données numériques

🌐 Garder uniquement les variables les plus informatives pour le modèle 🌐 Multiplier

ou croiser deux variables (ex. : $\text{prix_unitaire} \times \text{quantité} = \text{montant}$)

~~En feature engineering, vous pourriez :~~



III. Transformation 3. Features Engineering

Exemple:

Supposons que vous avez un jeu de données sur des achats clients :

- 🌐 Extraire "jour de la semaine", "mois", "saison" depuis date_achat
- 🌐 Calculer le nombre total d'achats par client_id
- 🌐 Encoder catégorie_produit avec One-Hot Encoding
- 🌐 Créer une variable prix_log = $\log(\text{prix} + 1)$ pour lisser les valeurs extrêmes

