



RAPPORT D'ANALYSE TECHNIQUE : DATASET TITANIC

Atelier N°2

Réalisé par :

Hdidou Yasser

Encadré par :

P FERDAOUS HDIOUD

Module :

GL pour l'IA



1. Introduction

Ce compte rendu présente l'analyse technique réalisée dans le cadre de l'Atelier N°2 portant sur le dataset Titanic, fourni par la bibliothèque Seaborn. Cette analyse exploratoire a pour but de répondre à 19 questions analytiques réparties en trois catégories : exploration des données, survie et statistiques, et corrélations avancées.

Le dataset Titanic est un jeu de données classique en Data Science, contenant des informations sur les passagers du célèbre paquebot qui a coulé en avril 1912. Il est couramment utilisé pour des analyses exploratoires et la construction de modèles prédictifs.

2. Chargement et Présentation du Dataset

2.1 Chargement des données

```
import seaborn as sns
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np

df = sns.load_dataset('titanic')
print(df.shape)          # (891, 15)
print(df.dtypes)
print(df.head())
```

2.2 Variables du dataset

Variable	Type	Description
survived	int (0/1)	Survie (0 = non, 1 = oui)
pclass	int (1/2/3)	Classe du billet
sex	catégorie	Sexe du passager
age	float	Âge du passager (années)
sibsp	int	Nb de frères/sœurs ou conjoints
parch	int	Nb de parents ou enfants
fare	float	Prix du billet
embark_town	catégorie	Port d'embarquement
class	catégorie	Classe (équivalent pclass)
who	catégorie	man / woman / child



alone	bool	Voyageait seul ?
-------	------	------------------

Partie I — Exploration des Données (Q1 à Q6)

Q1 — Nombre total de passagers

```
print(df.shape[0]) # Résultat : 891
```

Résultat	891 passagers dans le dataset
----------	-------------------------------

Le dataset contient 891 entrées représentant chacune un passager. Ce nombre correspond à un sous-ensemble des 2 224 personnes présentes à bord du Titanic.

Q2 — Répartition par classe (pclass)

```
print(df['pclass'].value_counts())
```

Classe	Nombre	Pourcentage
1ère Classe	216	24.2 %
2ème Classe	184	20.7 %
3ème Classe	491	55.1 %

La majorité des passagers voyageaient en 3ème classe (55%), reflétant la composition sociale de l'époque.

Q3 — Répartition par sexe

```
print(df['sex'].value_counts())
```

Hommes	577 passagers (64.8 %)
Femmes	314 passagers (35.2 %)

Les hommes représentaient près de deux tiers des passagers. Cette disparité aura une importance cruciale dans l'analyse de la survie.

Q4 & Q5 — Répartition des âges / Enfants vs Adultes

```
print(df['age'].describe())
```



```
df['age_group'] = df['age'].apply(lambda x: 'Enfant' if x < 18 else 'Adulte')
print(df['age_group'].value_counts())
```

Âge moyen	29.7 ans
Âge médian	28 ans
Âge minimum	0.42 an (nourrisson)
Âge maximum	80 ans
Enfants (< 18 ans)	113 passagers (16.2 %)
Adultes (>= 18 ans)	588 passagers (83.8 %)
Valeurs manquantes	177 valeurs (19.9 %)

La grande majorité des passagers était adulte. Les 177 valeurs manquantes sur l'âge représentent une limite importante pour l'analyse.

Q6 — Ports d'embarquement les plus fréquentés

```
print(df['embark_town'].value_counts())
```

Southampton (Angleterre)	644 passagers (72.3 %)
Cherbourg (France)	168 passagers (18.9 %)
Queenstown (Irlande)	77 passagers (8.7 %)

Southampton était de loin le port d'embarquement principal. Cherbourg accueillait notamment des passagers de 1ère classe.



Partie II — Survie et Statistiques (Q7 à Q12)

Q7 — Taux de survie global

```
print(df['survived'].value_counts(normalize=True) * 100)
```

Survivants	342 passagers — Taux de survie : 38.4 %
Décédés	549 passagers — Taux de mortalité : 61.6 %

Moins de 4 passagers sur 10 ont survécu au naufrage. Ce taux reflète la tragique réalité du désastre.

Q8 — Taux de survie selon la classe (pclass)

```
print(df.groupby('pclass')['survived'].mean() * 100)
```

1ère Classe	62.9 % de survivants
2ème Classe	47.3 % de survivants
3ème Classe	24.2 % de survivants

Il existe une corrélation très nette entre la classe et la survie : les passagers de 1ère classe avaient 2.6 fois plus de chances de survivre que ceux de 3ème classe. Les inégalités sociales ont joué un rôle déterminant.

Q9 — Taux de survie selon le sexe

```
print(df.groupby('sex')['survived'].mean() * 100)
```

Femmes	74.2 % de taux de survie
Hommes	18.9 % de taux de survie

Le principe « Women and children first » (Femmes et enfants d'abord) est clairement confirmé par les données. Les femmes avaient presque 4 fois plus de chances de survivre que les hommes.



Q10 — Différence de survie selon l'âge

```
survivors = df.groupby('survived')['age'].mean()
print(survivors)
```

Âge moyen des survivants	28.3 ans
Âge moyen des non-survivants	30.6 ans
Enfants survivants (< 18 ans)	~54 %
Adultes survivants (>= 18 ans)	~36 %

Les enfants avaient un taux de survie légèrement supérieur. Cependant, l'âge seul n'est pas un facteur aussi déterminant que le sexe ou la classe.

Q11 — Survie selon le port d'embarquement

```
print(df.groupby('embark_town')['survived'].mean() * 100)
```

Cherbourg	55.4 % de survivants
Queenstown	38.9 % de survivants
Southampton	33.7 % de survivants

Les passagers embarqués à Cherbourg ont eu le meilleur taux de survie. Cela s'explique principalement par le fait que ce port accueillait plus de passagers de 1ère classe.

Q12 — Influence du prix du billet (fare) sur la survie

```
print(df.groupby('survived')['fare'].mean())
```

Prix moyen (survivants)	48.4 £
Prix moyen (non-survivants)	22.1 £

Le prix du billet est fortement corrélé à la survie. Les passagers ayant payé davantage (donc en classes supérieures) avaient de bien meilleures chances de survie.

```
df['alone'] = df['family_size'] == 0
print(df.groupby('alone')['survived'].mean() * 100)
```



Voyager en famille offrait un avantage significatif en termes de survie, probablement grâce à la solidarité et à l'entraide lors de l'évacuation.

Q16 — Avantage des passagers les plus jeunes

```
df['age_group'] = pd.cut(df['age'], bins=[0,12,18,35,60,100],
                        labels=['Enfant', 'Ado', 'Jeune adulte', 'Adulte', 'Senior'])
print(df.groupby('age_group')['survived'].mean() * 100)
```

Enfant (0–12 ans)	~57.9 % de survie
Adolescent (12–18 ans)	~46.3 % de survie
Jeune adulte (18–35 ans)	~37.9 % de survie
Adulte (35–60 ans)	~39.9 % de survie
Senior (60+ ans)	~26.5 % de survie

Les jeunes enfants (0–12 ans) avaient le taux de survie le plus élevé, confirmant l'application du principe « Women and children first ». Les seniors étaient les plus vulnérables.

Q17 — Distribution des âges selon la classe

```
print(df.groupby('pclass')['age'].describe())
```

Classe	Âge moyen	Âge médian	Écart-type
1ère Classe	38.2 ans	37 ans	14.8
2ème Classe	29.9 ans	29 ans	14.0
3ème Classe	25.1 ans	24 ans	11.9

Les passagers de 1ère classe étaient en moyenne plus âgés (~38 ans), ce qui suggère un statut socio-économique établi. Les passagers de 3ème classe étaient majoritairement des jeunes adultes ou des immigrants.

Q18 — Billets les plus chers

```
top5 = df.nlargest(5, 'fare')[['name', 'pclass', 'fare', 'survived']]
print(top5)
```

Fare maximum	512.3 £ (équivalent ~50 000 £ aujourd'hui)
--------------	--

- age : imputation par la médiane ou par groupe (pclass + sex)
- embark_town : imputation par le mode (Southampton)
- deck : colonne à exclure ou traiter séparément (77% de données manquantes)



4. Conclusion et Synthèse

Cette analyse exploratoire du dataset Titanic a permis de mettre en évidence plusieurs facteurs déterminants dans la survie des passagers. Les principaux enseignements sont les suivants :

✓	Le sexe est le facteur de survie le plus déterminant : les femmes survivaient 4x plus que les hommes.
✓	La classe sociale avait un impact majeur : les passagers de 1ère classe survivaient 2.6x plus que ceux de 3ème classe.
✓	Le port d'embarquement (Cherbourg) était corrélé à un meilleur taux de survie, lié à la composition sociale.
✓	Les enfants bénéficiaient d'un léger avantage de survie grâce au protocole d'évacuation.
✓	Voyager en petite famille (1–3 membres) augmentait significativement les chances de survie.
✓	Le prix du billet reflète directement la classe et est donc corrélé positivement à la survie.
✓	Les valeurs manquantes (âge, deck) nécessitent un traitement avant modélisation prédictive.

Ce travail constitue une base solide pour la construction d'un modèle prédictif de classification (ex. : Random Forest, Logistic Regression) visant à prédire la survie de nouveaux passagers à partir des variables disponibles.